4. Foliensatz Betriebssysteme und Rechnernetze

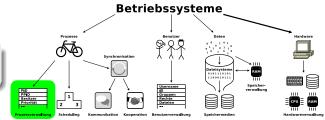
Prof. Dr. Christian Baun

Frankfurt University of Applied Sciences (1971-2014: Fachhochschule Frankfurt am Main) Fachbereich Informatik und Ingenieurwissenschaften christianbaun@fb2.fra-uas.de

Lernziele dieses Foliensatzes

- Am Ende dieses Foliensatzes kennen/verstehen Sie. . .
 - Was ein **Prozess** aus Sicht des Betriebssystems ist
 - Welche Informationen der Prozesskontext im Detail enthält
 - Benutzerkontext, Hardwarekontext, Systemkontext
 - die Prozesszustände anhand verschiedener Zustands-Prozessmodelle
 - wie das Prozessmanagement mit Prozesstabellen,
 Prozesskontrollblöcken und Zustandslisten funktioniert
 - wie das Erstellen und Löschen von Prozessen funktioniert
 - die Struktur von UNIX-Prozessen im Speicher
 - Was **Systemaufrufe** (System Calls) sind und wie sie funktionieren

Übungsblatt 4 wiederholt die für die Lernziele relevanten Inhalte dieses Foliensatzes



Prozess und Prozesskontext

Wir wissen bereits...

- Ein Prozess (lat. procedere = voranschreiten) ist eine Instanz eines Programms, das ausgeführt wird
- Prozesse sind dynamische Objekte und repräsentieren sequentielle Aktivitäten im Computer
- Auf Computern sind immer mehrere Prozesse in Ausführung
- Die CPU wird im raschen Wechsel zwischen den Prozessen hin- und hergeschaltet
- Ein Prozess umfasst außer dem Programmcode noch seinen Kontext
- 3 Arten von Kontextinformationen speichert das Betriebssystem:
 - Benutzerkontext
 - ullet Daten im zugewiesenen Adressraum (virtuellen Speicher) \Longrightarrow Foliensatz 2
 - Hardwarekontext (⇒ Folie 4)
 - Register in der CPU
 - Systemkontext (⇒ Folie 5)
 - Informationen, die das Betriebssystem über einen Prozess speichert
- Die Informationen im Hardwarekontext und Systemkontext verwaltet das Betriebssystem im Prozesskontrollblock (⇒ Folie 6)

Hardwarekontext

- Der Hardwarekontext umfasst die Inhalte der Register in der CPU zum Zeitpunkt der Prozess-Ausführung
- Register, deren Inhalt bei einem Prozesswechsel gesichert werden muss:
 - Befehlszähler (Program Counter, Instruction Pointer) enthält die Speicheradresse des nächsten auszuführenden Befehls
 - Stackpointer enthält die Speicheradresse am Ende des Stacks
 - Basepointer zeigt auf eine Adresse im Stack
 - Befehlsregister (Instruction Register) speichert den aktuellen Befehl
 - Akkumulator speichert Operanden für die ALU und deren Resultate
 - Page-table base Register Adresse wo die Seitentabelle des laufenden Prozesses anfängt
 - Page-table length Register Länge der Seitentabelle des laufenden Prozesses

Einige dieser Register wurden in Foliensatz 2 vorgestellt

Systemkontext

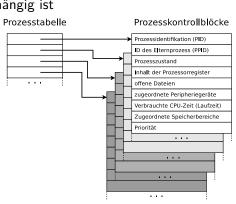
- Der Systemkontext sind die Informationen, die das Betriebssystem über einen Prozess speichert
- Beispiele:
 - Eintrag in der Prozesstabelle

Zustands-Prozessmodelle

- Prozessnummer (PID)
- Prozesszustand
- Information über Eltern- oder Kindprozesse
- Priorität
- Identifier Zugriffsrechte auf Ressourcen
- Quotas Zur Verfügung stehende Menge der einzelnen Ressourcen
- Laufzeit
- Geöffnete Dateien
- Zugeordnete Geräte

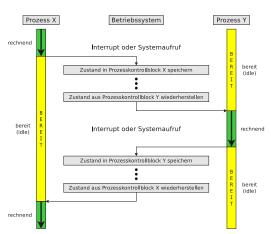
Prozesstabelle und Prozesskontrollblöcke

- Jeder Prozess hat seinen eigenen Prozesskontext, der von den Kontexten anderer Prozesse unabhängig ist
- Zur Verwaltung der Prozesse führt das Betriebssystem die Prozesstahelle
 - Es ist eine Liste aller existierenden Prozesse
 - Sie enthält für jeden Prozess einen Eintrag, den
 - Prozesskontrollblock



Prozesswechsel

- Beim Prozesswechsel werden der Systemkontext und der Hardwarekontext (⇒ Inhalt der CPU-Register) im Prozesskontrollblock gespeichert
- Erhält ein Prozess Zugriff auf die CPU, wird sein Kontext mit dem Inhalt des Prozesskontrollblocks wiederhergestellt



Jeder Prozess ist zu jedem Zeitpunkt in einem bestimmten Zustand
 Zustandsdiagramm der Prozesse

Prozesszustände

Wir wissen bereits...

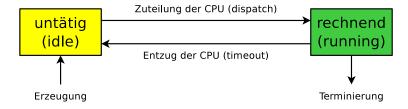
Jeder Prozess befindet sich zu jedem Zeitpunkt in einem Zustand

 Wie viele unterschiedliche Zustände es gibt, hängt vom Zustands-Prozessmodell des Betriebssystems ab

Frage

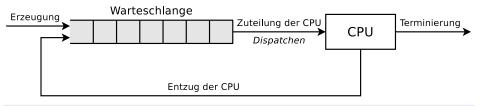
Wie viele Prozesszustände braucht ein Prozessmodell mindestens?

- Prinzipiell genügen 2 Prozesszustände
 - rechnend (running): Einem Prozess wurde die CPU zugeteilt
 - untätig (idle): Die Prozesse warten auf die Zuteilung der CPU



2-Zustands-Prozessmodell (Implementierung)

- Die Prozesse im Zustand untätig müssen in einer Warteschlange gespeichert werden, in der sie auf ihre Ausführung warten
 - Die Liste wird nach Prozesspriorität oder Wartezeit sortiert



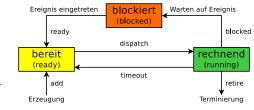
Die Priorität (anteilige Rechenleistung) hat unter Linux einen Wert von -20 bis +19 (in ganzzahligen Schritten). -20 ist die höchste Priorität und 19 die niedrigste Priorität. Die Standardpriorität ist 0. Normale Nutzer können Prioritäten von 0 bis 19 vergeben. Der Systemverwalter (root) darf auch negative Werte vergeben.

- Dieses Modell zeigt auch die Arbeitsweise des **Dispatchers**
 - Aufgabe des Dispatchers ist die Umsetzung der Zustandsübergänge
- Die Ausführungsreihenfolge der Prozesse legt der Scheduler fest, der einen Scheduling-Algorithmus (siehe Foliensatz 5) verwendet

Konzeptioneller Fehler des 2-Zustands-Prozessmodells

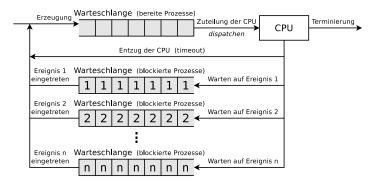
- Das 2-Zustands-Prozessmodell geht davon aus, dass alle Prozesse immer zur Ausführung bereit sind
 - Das ist unrealistisch!
- Es gibt fast immer Prozesse, die blockiert sind
 - Mögliche Gründe:
 - Warten auf die Eingabe oder Ausgabe eines E/A-Geräts
 - Warten auf das Ergebnis eines anderen Prozesses
 - Warten auf eine Reaktion des Benutzers
- Lösung: Die untätigen Prozesse werden in 2 Gruppen unterschieden
 - Prozesse die bereit (ready/idle) sind
 - Prozesse die **blockiert** (blocked) sind
- ⇒ 3-Zustands-Prozessmodell

- Jeder Prozess befindet sich in einem der folgenden Zustände:
- rechnend (running):
 - Der Prozess hat Zugriff auf die CPU und führt auf dieser Instruktionen aus



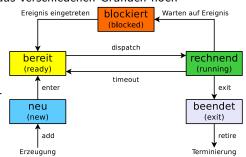
- bereit (ready/idle):
 - Der Prozess könnte unmittelbar Instruktionen auf der CPU ausführen und wartet aktuell auf die Zuteilung der CPU
- blockiert (blocked):
 - Der Prozess kann momentan nicht weiter ausgeführt werden und wartet auf das Eintreten eines Ereignisses oder die Erfüllung einer Bedingung
 - Dabei kann es sich z.B. um eine Nachricht eines anderen Prozesses oder eines Eingabe-/Ausgabegeräts oder um das Eintreten eines Synchronisationsereignisses handeln

• In der Praxis implementieren Betriebssysteme (z.B. Linux) mehrere Warteschlangen für Prozesse im Zustand **blockiert**



- Beim Zustandsübergang wird der Prozesskontrollblock des Prozesses aus der alten Zustandsliste entfernt und in die neue Zustandsliste eingefügt
- Für Prozesse im Zustand rechnend existiert keine eigene Liste

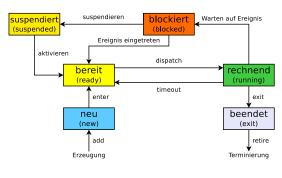
- Es ist empfehlenswert, das 3-Zustands-Prozessmodell um 2 weitere Prozesszustände zu erweitern
 - **neu** (new): Der Prozess (Prozesskontrollblock) ist erzeugt, wurde aber vom Betriebssystem noch nicht in die Warteschlange für Prozesse im Zustand bereit eingefügt
 - exit: Der Prozess ist fertig abgearbeitet oder wurde beendet, aber sein Prozesskontrollblock existiert aus verschiedenen Gründen noch
- Grund f
 ür die Existenz der Prozesszustände **neu** und **exit**:
 - Auf manchen Systemen ist die Anzahl der ausführbaren Prozesse limitiert, um Speicher zu sparen und den Grad des Mehrprogrammbetriebs festzulegen



- Ist nicht genügend physischer Hauptspeicher für alle Prozesse verfügbar, müssen Teile von Prozessen ausgelagert werden ⇒ Swapping
- Das Betriebssystem lagert Prozesse aus, die im Zustand blockiert sind
- Dadurch steht mehr Hauptspeicher den Prozessen in den Zuständen **rechnend** und bereit zur Verfügung

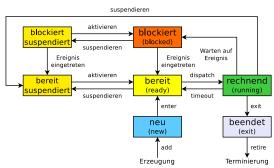
erweitern

• Es macht also Sinn, das 5-7ustands-Prozessmodell um den Prozesszustand suspendiert (suspended) zu



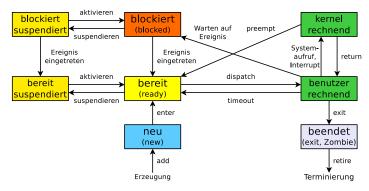
0000000000

- Wurde ein Prozess suspendiert, ist es besser, den frei gewordenen Platz im Hauptspeicher zu verwenden, um einen ausgelagerten Prozess zu aktivieren, als ihn einem neuen Prozess zuzuweisen
 - Das ist nur dann sinnvoll, wenn der aktivierte Prozess nicht mehr blockiert ist
- Im 6-7ustands-Prozessmodell fehlt die Möglichkeit, die ausgelagerten Prozesse zu unterscheiden in:
 - blockierte ausgelagerte Prozesse
 - nicht-blockierte ausgelagerte Prozesse



Prozessmodell von Linux/UNIX (etwas vereinfacht)

- Der Zustand rechnend (running) wird unterteilt in die Zustände...
 - benutzer rechnend (user running) für Prozesse im Benutzermodus
 - **kernel rechnend** (*kernel running*) für Prozesse im Kernelmodus



Ein Zombie-Prozess ist fertig abgearbeitet (via Systemaufruf exit), aber sein Eintrag in der Prozesstabelle existiert so lange, bis der Elternprozess den Rückgabewert (via Systemaufruf wait) abgefragt hat

Prozesse unter Linux/UNIX erzeugen mit fork (1/2)

- Der Systemaufruf fork() ist die üblicherweise verwendete Möglichkeit, einen neuen Prozess zu erzeugen
- Ruft ein Prozess fork() auf, wird eine identische Kopie als neuer Prozess gestartet
 - Der aufrufende Prozess heißt Vaterprozess oder Elternprozess
 - Der neue Prozess heißt Kindprozess
- Der Kindprozess hat nach der Erzeugung den gleichen Programmcode
 - Auch die Befehlszähler haben den gleichen Wert, verweisen also auf die gleiche Zeile im Programmcode
- Geöffnete Dateien und Speicherbereiche des Elternprozesses werden für den Kindprozess kopiert und sind unabhängig vom Elternprozess
 - Kindprozess und Elternprozess besitzen ihren eigenen Prozesskontext

Mit vfork existiert eine Variante von fork, die nicht den Adressraum des Elternprozesses kopiert, und somit weniger Verwaltungsaufwand als fork verursacht. Die Verwendung von vfork ist sinnvoll, wenn der Kindprozess direkt nach seiner Erzeugung durch einem anderen Prozess ersetzt werden soll. Für diese Vorlesung ist vfork nicht relevant.

Prozesse unter Linux/UNIX erzeugen mit fork (2/2)

- Ruft ein Prozess fork() auf, wird eine exakte Kopie erzeugt
 - Die Prozesse unterscheiden sich nur in den Rückgabewerten von fork()

```
#include <stdio.h>
   #include <unistd.h>
   #include <stdlib.h>
  void main() {
     int rueckgabewert = fork();
     if (rueckgabewert < 0) {
       // Hat fork() den Rückgabewert -1, ist ein Fehler aufgetreten.
10
       // Speicher oder Prozesstabelle sind voll.
11
12
13
     if (rueckgabewert > 0) {
14
       // Hat fork() einen positiven Rückgabewert, sind wir im Elternprozess.
15
       // Der Rückgabewert ist die PID des neu erzeugten Kindprozesses.
16
17
18
     if (rueckgabewert == 0) {
19
       // Hat fork() den Rückgabewert 0, sind wir im Kindprozess.
20
21
22
```

Prozessbaum

- Durch das Erzeugen immer neuer Kindprozesse mit fork() entsteht ein beliebig tiefer Baum von Prozessen (\Longrightarrow Prozesshierarchie)
- Das Kommando pstree gibt die laufenden Prozesse unter Linux/UNIX als Baum entsprechend ihrer Vater-/Sohn-Beziehungen aus

```
pstree
init-+-Xprt
     |-acpid
     |-gnome-terminal-+-4*[bash]
                       l-bash---su---bash
                       |-bash-+-gv---gs
                              I-pstree
                               |-xterm---bash---xterm---bash
                              |-xterm---bash---xterm---bash---xterm---bash
                               `-xterm---hash
                        -gnome-pty-helpe
                       `-{gnome-terminal}
     |-4*[gv---gs]
```

Informationen über Prozesse unter Linux/UNIX

```
$ ps -eFw
UID
       PID
           PPID
                        SZ
                              RSS PSR STIME TTY
                                                        TIME CMD
root
       1
                     51286
                             7432
                                    2 Apr11 ?
                                                    00:00:03 /sbin/init
      1073
                     90930
                             6508
                                    0 Apr11 ?
                                                    00:00:00 /usr/sbin/lightdm
root
           1073
                     60913
                             6772
                                    2 Apr11 ?
                                                    00:00:00 lightdm --session-child 14 23
      1551
root
      2143
           1551
                   1069
                            1560
                                    0 Apr11 ?
                                                    00:00:00 /bin/sh /etc/xdg/xfce4/xinitrc
bnc
      2235
           2143
                     85195
                            18888
                                    3 Apr11 ?
                                                    00:00:11 xfce4-session
bnc
      2284
           2235 0 110875
bnc
                            45256
                                    3 Apr11 ?
                                                    00:06:20 xfce4-panel --display :0.0
bnc
      2389
           2235
                 0 129173
                            47904
                                    0 Apr11 ?
                                                    00:00:26 xfce4-terminal --geometry=80x24
bnc
      2471
            2389
                      5374
                             5360
                                    2 Apr11 pts/0
                                                    00:00:00 bash
      2487
                  5 316370 395892
                                    0 Apr14 ?
                                                    00:08:58 /opt/google/chrome/chrome
bnc
           1
      2525
           2389
                      5895
                             6620
bnc
                                    3 Apr11 pts/5
                                                    00:00:00 bash
      3105
           2284
                 0 597319 257520
                                    0 Apr11 ?
                                                    00:05:22 kate -b
bnc
      3122
          3105 0
                                    2 Apr11 pts/6 00:00:00 /bin/bash
bnc
                      5364
                             5156
          2471
                                    0 Apr14 pts/0 00:00:25 okular bsrn_vorlesung_04.pdf
    11196
                 0 269491 181048
bnc
    16325
           1
                  0 346638 146872
                                    3 10:31 ?
                                                    00:00:16 evince BA.pdf
bnc
bnc
    17384
           2525
                  1 223478
                            61312
                                    2 10:39 pts/5
                                                    00:00:49 dia
    19561
           2471
                      9576
                             3340
                                    0 11:20 pts/0 00:00:00 ps -eFw
bn c
```

- C (CPU) = CPU-Belastung des Prozesses in Prozent
- SZ (Size) = Virtuelle Prozessgröße = Textsegment, Heap und Stack (siehe Folie 31)
- RSS (Resident Set Size) = Belegter physischer Speicher (ohne Swap) in kB
- PSR = Dem Prozess zugewiesener CPU-Kern
- STIME = Startzeitpunkt des Prozesses
- TTY (Teletypewriter) = Steuerterminal. Meist ein virtuelles Gerät: pts (pseudo terminal slave)
- TIME = Bisherige Rechenzeit des Prozesses auf der CPU (HH:MM:SS)

Unabhängigkeit von Eltern- und Kindprozess

 Das Beispiel zeigt, dass Eltern- und Kindprozess unabhängig voneinander arbeiten und unterschiedliche Speicherbereiche verwenden

```
#include <stdio h>
                                                                   Kind: 0
   #include <unistd.h>
                                                                   Kind · 1
   #include <stdlib.h>
                                                                   Kind · 21019
  void main() {
                                                                   Vater: 0
6
     int i:
       if (fork())
                                                                   Vater: 50148
         // Hier arbeitet der Vaterprozess
                                                                   Kind: 21020
9
         for (i = 0; i < 5000000; i++)
10
           printf("\n Vater: %i", i);
                                                                   Kind: 129645
11
       else
                                                                   Vater: 50149
12
         // Hier arbeitet der Kindprozess
13
        for (i = 0; i < 5000000; i++)
                                                                   Vater: 855006
14
           printf("\n Kind : %i", i):
                                                                   Kind: 129646
15
```

- In der Ausgabe sind die Prozesswechsel zu sehen
- Der Wert der Schleifenvariablen i beweist, dass Eltern- und Kindprozess unabhängig voneinander sind
 - Das Ergebnis der Ausführung ist nicht reproduzierbar

```
Ausführung auf nur einem CPU-Kern...
```

```
$ taskset --cpu-list 1 ./fork_beispiel2
```

<u>Die PID-Nummern</u> von Eltern- und Kindprozess (1/2)

```
#include <stdio.h>
   #include <unistd.h>
   #include <stdlib.h>
   void main() {
     int pid_des_Kindes;
8
     pid_des_Kindes = fork();
9
10
     // Es kam zu einem Fehler --> Programmabbruch
11
     if (pid_des_Kindes < 0) {
12
       perror("\n Es kam bei fork() zu einem Fehler!");
13
       exit(1):
14
15
16
     // Vaterprozess
17
     if (pid des Kindes > 0) {
18
       printf("\n Vater: PID: %i", getpid());
19
       printf("\n Vater: PPID: %i", getppid());
20
21
22
     // Kindprozess
23
     if (pid des Kindes == 0) {
24
       printf("\n Kind: PID: %i", getpid());
25
       printf("\n Kind: PPID: %i", getppid());
26
27
```

- Das Beispiel erzeugt einen Kindprozess
- Kindprozess und Vaterprozess geben beide aus:
 - Eigene PID
 - PID des Vaters (PPID)

Die PID-Nummern von Eltern- und Kindprozess (2/2)

• Die Ausgabe ist üblicherweise mit dieser vergleichbar:

```
Vater: PID: 20952
Vater: PPID: 3904
Kind: PID: 20953
Kind: PPID: 20952
```

Gelegentlich kann man folgendes Ereignis beobachten:

```
Vater: PID: 20954
Vater: PPID: 3904
Kind: PID: 20955
Kind: PPID: 1
```

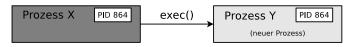
- Der Elternprozess wurde vor dem Kind-Prozess beendet
 - Wird der Elternprozess vor dem Kindprozess beendet, bekommt er init als neuen Elternprozess zugeordnet
 - Elternlose Prozesse werden immer von init adoptiert

init (PID 1) ist der erste Prozess unter Linux/UNIX

Alle laufenden Prozesse stammen von init ab \Longrightarrow init = Vater aller Prozesse

Prozesse ersetzen mit exec

- Der Systemaufruf exec() ersetzt einen Prozess durch einen anderen
 - Es findet eine Verkettung statt
 - Der neue Prozess erbt die PID des aufrufenden Prozesses
- Will man aus einem Prozess heraus ein Programm starten, ist es nötig, zuerst mit fork() einen neuen Prozess zu erzeugen und diesen mit exec() zu ersetzen
 - Wird vor einem Aufruf von exec() kein neuer Prozess mit fork() erzeugt, geht der Elternprozess verloren
- Schritte einer Programmausführung in der Shell:
 - Die Shell erzeugt mit fork() eine identische Kopie von sich selbst
 - Im neuen Prozess wird mit exec() das eigentliche Programm gestartet



Beispiel zum Systemaufruf exec

```
$ ps -f
UID
          PID
                PPID
                      C STIME TTY
                                            TIME CMD
          1772 1727
                      0 May18 pts/2
user
                                       00:00:00 bash
         12750 1772
                      0 11:26 pts/2
                                       00:00:00 ps -f
user
$ bash
$ ps -f
UID
          PID
                PPID
                      C STIME TTY
                                            TIME CMD
          1772 1727 0 May18 pts/2
                                       00:00:00 bash
user
    12751 1772 12 11:26 pts/2
                                       00:00:00 bash
user
         12769
               12751
                      0 11:26 pts/2
                                       00:00:00 ps -f
user
$ exec ps -f
UID
         PID
                PPID
                      C STIME TTY
                                            TIME CMD
          1772 1727
                      0 May18 pts/2
                                       00:00:00 bash
user
                      4 11:26 pts/2
                                       00:00:00 ps -f
         12751 1772
user
$ ps -f
UID
           PID
                PPID
                      C STIME TTY
                                            TIME CMD
          1772
                1727
                      0 May18 pts/2
                                       00:00:00 bash
user
         12770
                1772
                      0 11:27 pts/2
                                       00:00:00 ps -f
user
```

 Durch das exec hat ps -f die Bash ersetzt und deren PID (12751) und PPID (1772) übernommen

Ein weiteres Beispiel zu exec

```
#include <stdio.h>
   #include <unistd.h>
   int main() {
       int pid:
       pid = fork();
       // Wenn die PID!=0 --> Elternprozess
       if (pid) {
10
           printf("...Elternprozess...\n");
11
           printf("[Eltern] Eigene PID:
                                             %d\n", getpid());
12
           printf("[Eltern] PID des Kindes: %d\n", pid);
13
14
       // Wenn die PID=0 --> Kindprozess
15
       else {
16
           printf("...Kindprozess...\n");
17
           printf("[Kind] Eigene PID:
                                             %d\n", getpid());
18
           printf("[Kind] PID des Vaters: %d\n", getppid());
19
20
           // Aktuelles Programm durch "date" ersetzen
21
           // "date" wird der Prozessname in der Prozesstabelle
22
           execl("/bin/date", "date", "-u", NULL):
23
24
       printf("[%d]Programmende\n", getpid());
25
       return 0:
26 F
```

- Der Systemruf exec()
 existiert nicht als Bibliotheksfunktion
- Aber es
 existieren
 mehrere
 Varianten der
 Funktion
 exec()
- Eine Variante ist execl()

Hilfreiche Übersicht über die verschiedene Varianten der Funktion exec()

Erklärung zum exec Beispiel

```
$ ./exec_beispiel
...Elternprozess...
[Eltern] Eigene PID:
                          25492
[Eltern] PID des Kindes:
                          25493
[25492] Programmende
...Kindprozess...
[Kind] Eigene PID:
                          25493
[Kind]
         PID des Vaters:
                          25492
Di 24. Mai 17:16:48 CEST 2016
$ ./exec_beispiel
...Elternprozess...
[Eltern] Eigene PID:
                          25499
[Eltern] PID des Kindes:
                          25500
[25499] Programmende
...Kindprozess...
[Kind]
         Eigene PID:
                          25500
[Kind]
         PID des Vaters:
Di 24. Mai 17:17:15 CEST 2016
```

- Der Kindprozess wird nach der Ausgabe seiner PID mit getpid() und der PID seines Elternprozesses mit getppid() durch date ersetzt
- Wird der Elternprozess vor dem Kindprozess beendet, bekommt der Kindprozess init als neuen Elternprozess zugeordnet

Seit Linux Kernel 3.4 (2012) und Dragonfly BSD 4.2 (2015) können auch andere Prozesse als PID=1 neue Elternprozesse eines verweisten Kindprozesses werden http://unix.stackexchange.com/questions/149319/new-parent-process-when-the-parent-process-dies/1773614

3 Möglichkeiten um einen neuen Prozess zu erzeugen

- Prozessvergabelung (forking): Ein laufender Prozess erzeugt mit fork() einen neuen, identischen Prozess
- Prozessverkettung (chaining): Ein laufender Prozess erzeugt mit exec() einen neuen Prozess und beendet (terminiert) sich damit selbst, weil er durch den neuen Prozess ersetzt wird
- Prozesserzeugung (creation): Ein laufender Prozess erzeugt mit fork() einen neuen, identischen Prozess, der sich selbst mit exec() durch einen neuen Prozess ersetzt



Spaß haben mit Forkbomben

- Eine Forkbombe ist ein Programm, das den Systemaufruf fork in einer Endlosschleife aufruft
- Ziel: So lange Kopien des Prozesses erzeugen, bis kein Speicher mehr frei ist
 - Das System wird unbenutzbar

Forkbombe in Python

```
import os

while True:
    os.fork()
```

Forkbombe in C

```
1 #include <unistd.h>
2
3 int main(void)
4 {
5     while(1)
6     fork();
7 }
```

Forkbombe in PHP

```
1 <?php
2 while(true)
3     pcntl_fork();
4 ?>
```

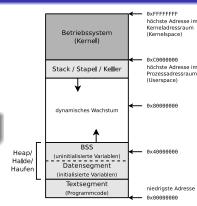
 Einzige Schutzmöglichkeit: Maximale Anzahl der Prozesse und maximalen Speicherverbrauch pro Benutzer limitieren

Struktur eines UNIX-Prozesses im Speicher (1/6)

- Standardmäßige Aufteilung des virtuellen Speichers auf einem Linux-System mit 32-Bit-CPU
 - 1 GB sind für das System (Kernel)
 - 3 GB für den laufenden Prozess

Die Struktur von Prozessen auf 64 Bit-Systemen unterscheidet sich nicht von 32 Bit-Systemen. Einzig der Adressraum ist größer und damit die mögliche Ausdehnung der Prozesse im Speicher

- Das Textsegment enthält den Programmcode (Maschinencode)
- Können mehrere Prozessen teilen
 - Muss also nur einmal im physischen Speicher vorgehalten werden
 - Ist darum üblicherweise nur lesbar (read only)
- Liest exec() aus der Programmdatei

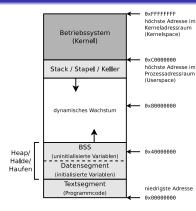


Quellen

Struktur eines UNIX-Prozesses im Speicher (2/6)

- Der **Heap** wächst dynamisch und besteht aus 2 Teilen:
 - Datensegment
 - BSS
- Das Datensegment enthält initialisierte Variablen und Konstanten
 - Enthält alle Daten, die ihre Werte in globalen Deklarationen (außerhalb von Funktionen) zugewiesen bekommen
 - Beispiel: int summe = 0;
 - Liest exec() aus der Programmdatei

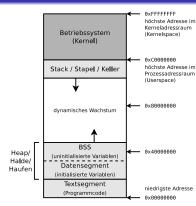
Der Userspace in der dargestellten Speicherstruktur der Prozesse entspricht dem Benutzerkontext (siehe Folie 3). Das ist der vom Betriebssystem zugewiesene virtuelle Adressraum (virtuelle Speicher) \Longrightarrow siehe Foliensatz 2



Quellen

Struktur eines UNIX-Prozesses im Speicher (3/6)

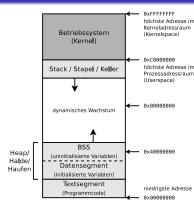
- Der Bereich BSS (Block Started by Symbol) enthält nicht initialisierte Variablen
- Enthält globale Variablen (Deklaration ist außerhalb von Funktionen), denen kein Anfangswert zugewiesen wird
 - Beispiel: int i;
- Zudem kann hier der Prozess dynamisch zur Laufzeit Speicher allokieren
 - Unter C mit der Funktion malloc()
- Alle Variablen im BSS initialisiert exec() mit 0



Quellen

Struktur eines UNIX-Prozesses im Speicher (4/6)

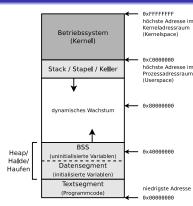
- Der Stack dient zur Realisierung geschachtelter Funktionsaufrufe
 - Enthält auch die Kommandozeilenargumente des Programmaufrufs und Umgebungsvariablen
- Arbeitet nach dem Prinzip LIFO (Last In First Out)



Quellen

Struktur eines UNIX-Prozesses im Speicher (5/6)

- Mit jedem Funktionsaufruf wird eine Datenstruktur mit folgendem Inhalt auf den Stack gelegt:
 - Aufrufparameter
 - Rücksprungadresse
 - Zeiger auf die aufrufende Funktion im Stack
- Die Funktionen legen auch ihre lokalen Variablen auf den Stack
- Beim Rücksprung aus einer Funktion wird die Datenstruktur der Funktion aus dem Stack entfernt

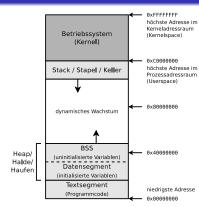


Quellen

Struktur eines UNIX-Prozesses im Speicher (6/6)

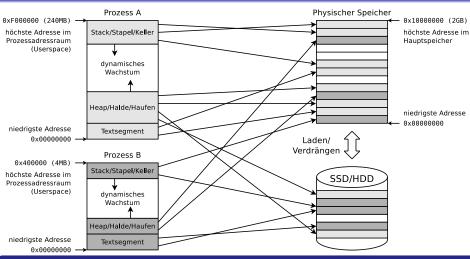
- Das Kommando size gibt die Größe (in Bytes) von Textsegment, Datensegment und BSS von Programmdateien aus
 - Die Inhalte von Textsegment und Datensegment sind in den Programmdateien enthalten
 - Alle Inhalte im BSS werden bei der Prozesserzeugung auf den Wert 0 gesetzt

\$ size /	/bin/c*					
text	data	bss	dec	hex	filename	
46480	620	1480	48580	bdc4	/bin/cat	
7619	420	32	8071	1f87	/bin/chacl	
55211	592	464	56267	dbcb	/bin/chgrp	
51614	568	464	52646	cda6	/bin/chmod	
57349	600	464	58413	e42d	/bin/chown	
120319	868	2696	123883	1e3eb	/bin/cp	
131911	2672	1736	136319	2147f	/bin/cpio	



Quellen

Wiederholung: Virtueller Speicher (Foliensatz 2)



 $Quelle: \ \texttt{http://cseweb.ucsd.edu/classes/will/csel41/Slides/19_VirtualMemory.key.pdf}$

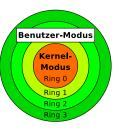
Die Ablage der Prozesse im (hier 2 GB großen) physischen Speicher erfolgt durch den virtuellen Speicher nicht in fortlaufender Weise und auch nicht zwangsläufig ständig im Hauptspeicher

Benutzermodus und Kernelmodus

- x86-kompatible CPUs enthalten 4 Privilegienstufen
 - Ziel: Stabilität und Sicherheit verbessern
 - Jeder Prozess wird in einem Ring ausgeführt und kann sich nicht selbstständig aus diesem befreien

Realisierung der Privilegienstufen

- Das Register CPL (Current Privilege Level) speichert die aktuelle Privilegienstufe
- Quelle: Intel 80386 Programmer's Reference Manual 1986 http://css.csail.mit.edu/6.858/2012/readings/i386.pdf



- In Ring 0 (= **Kernelmodus**) läuft der Betriebssystemkern
 - Hier haben Prozesse vollen Zugriff auf die Hardware
 - ullet Der Kern kann auch physischen Speicher adressieren (\Longrightarrow Real Mode)
- In Ring 3 (= **Benutzermodus**) laufen die Anwendungen
 - Hier arbeiten Prozesse nur mit virtuellem Speicher (⇒ Protected Mode)

Moderne Betriebssysteme verwenden nur 2 Privilegienstufen (Ringe)

Systemaufrufe (1/2)

Wir wissen bereits...

Alle Prozesse außerhalb des Betriebssystemkerns dürfen ausschließlich auf ihren eigenen virtuellen Speicher zugreifen

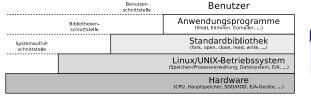
- Muss ein Prozess im Benutzermodus eine höher privilegierte Aufgabe erfüllen (z.B. Zugriff auf Hardware), kann er das dem Kernel durch einen Systemaufruf mitteilen
 - Ein Systemaufruf ist ein Funktionsaufruf im Betriebssystem, der einen Sprung vom Benutzermodus in den Kernelmodus auslöst (⇒ Moduswechsel)

Moduswechsel

- Ein Prozess gibt die Kontrolle über die CPU an den Kernel ab und ist unterbrochen bis die Anfrage fertig bearbeitet ist
- Nach dem Systemaufruf gibt der Kernel die CPU wieder an den Prozess im Benutzermodus ab
- Der Prozess führt seine Abarbeitung an der Stelle fort, an der der Prozesswechsel zuvor angefordert wurde
- Die Leistung eines Systemaufrufs wird im Kernel erbracht
 - Also außerhalb des Adressraums des aufrufenden Prozesses

Systemaufrufe (2/2)

- Systemaufrufe (System Calls) sind die Schnittstelle, die das Betriebssystem den Prozessen im Benutzermodus zur Verfügung stellt
 - Systemaufrufe erlauben den Prozessen im Benutzermodus u.a. Prozesse und Dateien zu erzeugen und zu verwalten und auf Hardware zuzugreifen

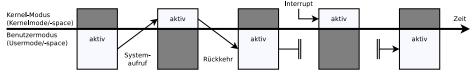


Einfach gesagt...

Ein Systemaufruf ist eine Anfrage eines Prozesses im Benutzermodus an den Kernel. um einen Dienst des Kernels zu nutzen

Vergleich zwischen Systemaufrufen und Interrupts

Interrupts sind Unterbrechungen, die Ereignisse außerhalb von Prozessen im Benutzermodus auslösen



Ein Beispiel für einen Systemaufruf: ioctl()

- Mit ioctl() setzen Linux-Programme gerätespezifische Befehle ab
 - Er ermöglicht Prozessen die Kommunikation mit und Steuerung von:
 - Zeichenorientierten Geräten (Maus, Tastatur, Drucker, Terminals, ...)
 - Blockorientierten Geräten (SSD/HDD, CD-/DVD-Laufwerk, ...)
- Syntax:

ioctl (Filedeskriptor, Aktionsanforderung, Integer-Wert oder Zeiger auf Daten);

- Einige typische Einsatzszenarien von ioctl():
 - Diskettenspur formatieren
 - Modem oder Soundkarte initialisieren
 - CD auswerfen
 - Status- und Verbindungsinformationen der WLAN-Schnittstelle auslesen
 - ullet Auf Sensoren via Inter-Integrated Circuit (I 2 C) Datenbus zugreifen

Gute Übersichten über Systemaufrufe

Linux: http://www.digilife.be/quickreferences/qrc/linux%20system%20call%20quick%20reference.pdf

Linux: http://syscalls.kernelgrok.com

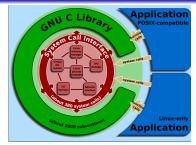
Linux: http://www.tutorialspoint.com/unix_system_calls/

Windows: http://j00ru.vexillium.org/ntapi

Systemaufrufe und Bibliotheken

- Direkt mit Systemaufrufen arbeiten ist unsicher und schlecht portabel
- Moderne Betriebssysteme enthalten eine Bibliothek, die sich logisch zwischen den Benutzerprozessen und dem Kern befindet

Beispiele für solche Bibliotheken GNU C-Bibliothek glibc (Linux), C Standard Library (UNIX), C Library Implementation (BSD), Native API ntdl1.dl1 (Windows)

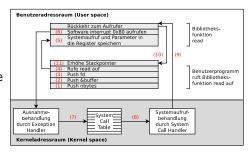


Bildquelle: Wikipedia (Shmuel Csaba Otto Traian, CC-BY-SA-3.0)

- Die Bibliothek ist zuständig für:
 - Kommunikationsvermittlung der Benutzerprozesse mit dem Kernel
 - Moduswechsel zwischen Benutzermodus und Kernelmodus.
- Vorteile, die der Einsatz einer Bibliothek mit sich bringt:
 - Erhöhte **Portabilität**, da kein oder nur sehr wenig Bedarf besteht, dass die Benutzerprozesse direkt mit dem Kernel kommunizieren
 - Erhöhte Sicherheit, da die Benutzerprozesse nicht selbst den Wechsel in den Kernelmodus durchführen können

Schritt für Schritt (1/4) - read(fd, buffer, nbytes);

- In Schritt 1-3 legt der Benutzerprozess die Parameter auf den Stack
- In 4 ruft der Benutzerprozess die Bibliotheksfunktion für read (⇒ nbytes aus der Datei fd lesen und in buffer speichern) auf

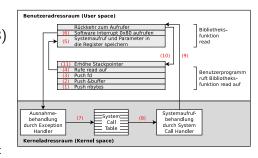


- Die Bibliotheksfunktion speichert in 5 die Nummer des Systemaufrufs im Accumulator Register EAX (32-Bit) bzw. RAX (64-Bit)
 - Die Bibliotheksfunktion speichert die Parameter des Systemaufrufs in den Registern EBX, ECX und EDX (bzw. bei 64-Bit: RBX, RCX und RDX)

Quelle dieses Beispiels

Moderne Betriebssysteme, Andrew S. Tanenbaum, 3. Auflage, Pearson (2009), S.84-89

- In 6 wird der Softwareinterrupt (Exception) 0x80 (dezimal: 128) ausgelöst, um vom Benutzermodus in den Kernelmodus zu wechseln
 - Der Softwareinterrupt unterbricht die Programmausführung im Benutzermodus und erzwingt das Ausführen eines Exception-Handlers im Kernelmodus

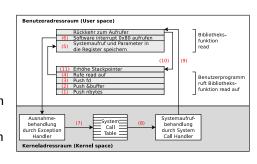


Der Kernel verwaltet die System Call Table, eine Liste mit allen Systemaufrufen

Jedem Systemaufruf ist dort eine eindeutige Nummer und eine Kernel-interne Funktion zugeordnet

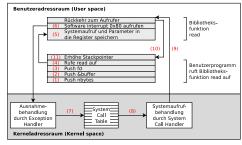
Schritt für Schritt (3/4) - read(fd, buffer, nbytes);

- Der aufgerufene
 Exception-Handler ist eine
 Funktion im Kernel, die das
 Register EAX ausliest
- Die Exception-Handler-Funktion ruft in 7 die entsprechende Kernel-Funktion aus der System Call Table mit den in den Registern EBX, ECX und EDX (bzw. RBX, RCX und RDX) liegenden Argumenten auf
- In 8 startet der Systemaufruf
- In 9 gibt der Exception-Handler die Kontrolle an die Bibliothek zurück, die den Softwareinterrupt auslöste



Schritt für Schritt (4/4) – read(fd, buffer, nbytes);

- Die Funktion kehrt danach in 10 zum Benutzerprozess so zurück, wie es auch eine normale Funktion getan hätte
- Um den Systemaufruf abzuschließen, muss der Benutzerprozess in 11 genau wie nach jedem Funktionsaufruf den Stack aufräumen



• Anschließend kann der Benutzerprozess weiterarbeiten

Die beschriebene Arbeitsweise mit Exception 0x80 funktioniert unter 32-Bit und in den meisten Fällen auch unter 64-Bit Betriebssystemen. Unter 64-Bit Betriebssystemen gilt dieses Arbeitsweise aber als veraltet und langsam. Die modernere Arbeitsweise ist die Verwendung der Anweisung syscall (unistd.h) und den Registern RAX für die Nummer des Systemaufrufs und RDI, RSI, und RDX für die Parameter.

Weitere Informationen:

https://blog.packagecloud.io/the-definitive-guide-to-linux-system-calls/ https://stackoverflow.com/questions/2535989/ what-are-the-calling-conventions-for-unix-linux-system-calls-and-user-space-f

- Systemaufrufe werden wie Bibliotheksfunktionen aufgerufen
 - Der Mechanismus ist bei allen Betriebssystemen ähnlich
 - In einem C-Programm ist kein Unterschied erkennbar

```
1 #include <syscall.h>
 2 #include <unistd.h>
 3 #include <stdio.h>
   #include <svs/tvpes.h>
   int main(void) {
 7
     unsigned int ID1, ID2;
 8
     // Systemaufruf
10
    ID1 = syscall(SYS getpid):
11
     printf ("Ergebnis des Systemaufrufs: %d\n", ID1);
12
13
     // Von der glibc aufgerufener Systemaufruf
14
     ID2 = getpid();
15
     printf ("Ergebnis der Bibliotheksfunktion: %d\n", ID2);
16
17
     return(0):
18 }
```

```
$ gcc SysCallBeispiel.c -o SysCallBeispiel
$ ./SysCallBeispiel
Ergebnis des Systemaufrufs: 3452
Ergebnis der Bibliotheksfunktion: 3452
```

Auswahl an Systemaufrufen

	fork	Neuen Kindprozess erzeugen
Prozess-	waitpid	Auf Beendigung eines Kindprozesses warten
verwaltung	execve	Einen Prozess durch einen anderen ersetzen. PID beibehalten
	exit	Prozess beenden
Ī	open	Datei zum Lesen/Schreiben öffnen
5	close	Offene Datei schließen
Datei-	read	Daten aus einer Datei in den Puffer einlesen
verwaltung	write	Daten aus dem Puffer in eine Datei schreiben
	lseek	Dateipositionszeiger positionieren
	stat	Status einer Datei ermitteln
	mkdir	Neues Verzeichnis erzeugen
	rmdir	Leeres Verzeichnis entfernen
Verzeichnis-	link	Neuen Verzeichniseinträg (Link) auf eine Datei erzeugen
verwaltung	unlink	Verzeichniseintrag löschen
	mount	Dateisystem in die hierarchische Verzeichnisstruktur einhängen
	umount	Eingehängtes Dateisystem aushängen
	chdir	Aktuelles Verzeichnis wechseln
Verschiedenes	chmod	Dateirechte für eine Datei ändern
	kill	Signal an einen Prozess schicken
	time	Sekunden seit dem 1. Januar 1970 ("Unixzeit") ausgeben

Systemaufrufe unter Linux

- Die Liste mit den Namen der Systemaufrufe im Linux-Kernel...
 - befindet sich im Quelltext von Kernel 2.6.x in der Datei: arch/x86/kernel/syscall table 32.S
 - befindet sich im Quelltext von Kernel 3.x, 4.x und 5.x in diesen Dateien: arch/x86/syscalls/syscall [64|32].tbl oder arch/x86/entry/syscalls/syscall [64|32].tbl

```
arch/x86/syscalls/syscall 32.tbl
                                          svs exit
        i386
                 exit
        i386
                 fork
                                          sys_fork
        i386
                 read
                                          svs read
        i386
                 write
                                          svs write
        i386
                                          sys_open
                 open
        i386
                 close
                                          sys_close
```

Anleitungen, wie man eigene Systemaufrufe realisiert

http://www.ibm.com/developerworks/library/l-system-calls/

```
https://www.kernel.org/doc/html/v4.14/process/adding-syscalls.html
https://brennan.io/2016/11/14/kernel-dev-ep3/
https://medium.com/@ieremyphilemon/adding-a-guick-system-call-to-the-linux-kernel-cad55b421a7b
https://medium.com/@ssreehari/implementing-a-system-call-in-linux-kernel-4-7-1-6f98250a8c38
http://tldp.org/HOWTO/Implement-Sys-Call-Linux-2.6-i386/index.html
```